

Phylogénie sans vraisemblance



Luc Blassel


Auditions CNRS 51/02

20 Mai 2026

transparent: lucblassel.com/files/CNRS_5102_2026.pdf

1. Ingénieur **AgroParisTech** 2014-2018
 - Spécialisation **IODAA** & double-cursus
M2 **IASD** à **Dauphine**
2. Pré-doc & Thèse à **l'Institut Pasteur** 2018-2022
 - *R. Chikhi*: **Amélioration d'alignement** de séquences
 - *O. Gascuel*: **Apprentissage** à partir d'alignements
3. Post-doc au **LBBE & CQSB** 2023-
 - *L. Jacob*: **Inférence** phylogénétique **sans vraisemblance**

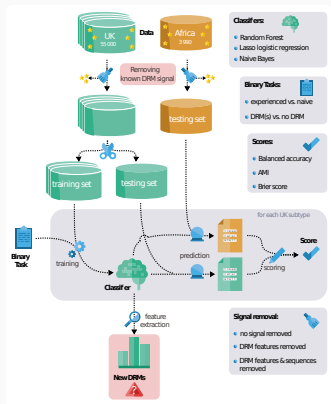
Travaux antérieurs



- **Objectif:** Améliorer l'alignement de lectures ONT à une référence
- **Méthode:** Transformer les séquences et aligner dans l'espace transformé
- **Résultats:** 58 fonctions de transformation identifiées
- **Impact:** Adapté pour l'assemblage de lectures ONT¹

Blassel, Medvedev, et al. [2022](#)

¹Faure, Hilaire, et al. [2025](#)



- **Objectif:** Trouver des mutations de résistances du VIH
- **Méthode:** Entraînement de classifieurs interprétables *traité/non-traité*
- **Résultats:** Identification de 6 nouvelles mutations potentiellement accessoires

Blassel, Tostevin, et al. 2021; Blassel, Zhukova, et al. 2021

Projet de recherche - Phylogénie sans vraisemblance

Inférence phylogénétique:

- x : alignement de **séquences**, θ : **arbre**,
- $p(x|\theta, M)$: **modèle** d'évolution

Fréquentiste: $\theta^* = \underset{\theta}{\operatorname{argmax}} p(x|\theta, M)$?

Bayésien: $P(\theta|x, M)$?

Inférence conditionnée sur un arbre:

- **Processus générateur**, e.g. modèle épidémio. avec R_0
- $P(R_0|\theta)$, $P(R_0|\theta, x)$, ...?

Problème:

Repose sur des **calculs répétés** de la **vraisemblance**

But:

Développer des **méthodes** phylogénétiques **sans vraisemblance**


1. Inférence phylogénétique

- **Estimation** neurale de **Postérieure**:
(1) **sans alignement**, (2) sans assemblage
- Modèles de **Diffusion** sur l'espace des arbres


2. Inférence conditionnée sur un arbre

- Approche par GNN
- **Inférence jointe** arbre/paramètres

Training time





Inference time




Nesterenko, Blassel, et al. 2025


- **Objectif:** Prédire une matrice de distance phylogénétique correspondant à un alignement
- **Méthode:** Entraîner un transformer axial dans l'espace des paires de séquences
- **Résultats:** État de l'art dans la prédiction de distances
- **Limites:** Écart de performance en prédiction topologique




- À l'entraînement $\psi^* = \underset{\psi}{\operatorname{argmin}} - \sum_{i \in \text{train}} \log q_{\psi(x_i)}(\theta_i|x_i)$
- Pendant l'inférence on échantillonne $q_{\psi^*(x_E)}(\theta_E|x_E)$




$$q_{\psi(x)}(\theta|x) = ?$$




$$q_{\psi(x)}(\theta|x) = p(m^{(1)})$$



$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)})$$



$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)}) \times p(m^{(3)}|m^{(1,2)})$$



$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)}) \times p(m^{(3)}|m^{(1,2)}) \times p(m^{(4)}|m^{(1,2,3)})$$

Projet - Estimation de Postérieure sans alignement

- On garde la même méthode pour calculer $q_{\psi(x)}(\theta|x)$
- Il faut un nouvel encodeur pour obtenir $\psi(x)$
- Remplacer les blocs d'attention axiale:
 1. Cross-attention entre chaque séquence et un embedding "CLS"
 2. Self-attention entre les embeddings "CLS"
 3. Cross-attention entre les embeddings "CLS" et les séquences
- perspectives futures: sans assemblage avec les sets transformers/performer

Projet - Diffusion dans l'espace des arbres

- Ici approche très différente, basée sur les modèles de diffusion discrets
- On bruite un arbre et on apprend à "dé-bruiter"
- Processus de bruit:
 - mouvements topologique sur les arbres
 - Distribution du bruit = distribution catégorique sur les mouvements topologiques
- TODO: schema exemple de mouvements topologiques et processus de bruitage

- Exemple concret: reconstruction de séquence ancestrale
- Ici on modifie légèrement la manière de calculer la probabilité
 - On rajoute des embeddings supplémentaires par noeud: e.g. distributions catégoriques de caractères/séquences
 - Entraînement sur données simulées (on connaît l'état des noeuds internes)
 - Inférence: on peut échantillonner les séquences ancestrales

- **Passage à l'échelle:**
 - Appliquer ces méthodes sur $10^3, 4, 5 \dots$ séquences.
 - Remplacer l'auto-attention par des approches de meilleur complexité
- **Inférence de réseaux phylogénétiques:**
 - Pour pouvoir modéliser les transferts horizontaux ou la recombinaison les arbres ne sont pas suffisants
 - L'inférence de réseaux est beaucoup plus compliqué
 - Inférence sans vraisemblance aurait un gros impact sur l'utilisation pratique des réseaux

CQSB:

Expertise: ML (L. Jacob), Évolution (M. Weigt, A. Carbone)

Collaborations: L. Jacob & P. Barrat-Charlaix

Équipe Bioinfo au LISN:

Expertise: SBI (F. Pouyet, F. Jay), Arbres & Graphes (L. Planche)

Équipe Modelling of Pathogens à l'IBENS & IP:

Expertise: Évolution & Phylogénie (A. Zhukova, H. Morlon)

Collaborations: A. Zhukova

References

- Blassel, L. et al. (2021). **Drug Resistance Mutations in HIV: New Bioinformatics Approaches and Challenges.** In: *Current Opinion in Virology* 51, pp. 56–64.
- Blassel, L. et al. (2021). **Using Machine Learning and Big Data to Explore the Drug Resistance Landscape in HIV.** In: *PLOS Computational Biology* 17.8, e1008873.
- Blassel, L. et al. (2022). **Mapping-Friendly Sequence Reductions: Going beyond Homopolymer Compression.** In: *iScience*, p. 105305.
- Faure, R. et al. (2025). **Alice: Fast and Haplotype-Aware Assembly of High-Fidelity Reads Based on MSR Sketching.** Pre-published.
- Nesterenko, L. et al. (2025). **Phyloformer: Fast, Accurate, and Versatile Phylogenetic Reconstruction with Deep Neural Networks.** In: *Molecular Biology and Evolution* 42.4, msaf051.

Transparents additionels

Schema

Projet - Inférence de séquences d'arbres

frame

Projet - Inférence sur les arbres par GNN

frame

env