

Phylogénie sans vraisemblance



Luc Blassel


Auditions CNRS 51/02

20 Mai 2026

1. Ingénieur **AgroParisTech** 2014-2018
 - Spécialisation **IODAA** & double-cursus
M2 **IASD** à **Dauphine**
2. Pré-doc & Thèse à **l'Institut Pasteur** 2018-2022
 - *R. Chikhi*: **Amélioration d'alignement** de séquences
 - *O. Gascuel*: **Apprentissage** à partir d'alignements
3. Post-doc au **LBBE & CQSB** 2023-
 - *L. Jacob*: **Inférence** phylogénétique **sans vraisemblance**

Travaux antérieurs

Travaux - Amélioration d'alignements (Thèse)

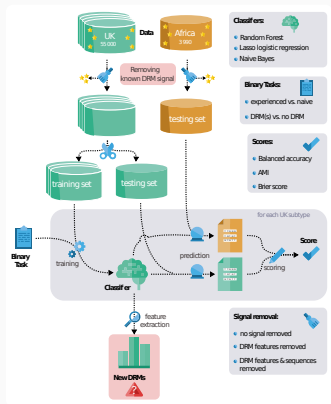


- **Objectif:** Améliorer l'alignement de lectures ONT à une référence
- **Méthode:** Transformer les séquences et aligner dans l'espace transformé
- **Résultats:** 58 fonctions de transformation identifiées
- **Impact:** Adapté pour l'assemblage de lectures ONT¹

Blassel, Medvedev, et al. [2022](#)

¹Faure, Hilaire, et al. [2025](#)

Travaux - Apprentissage sur alignements (Thèse)



- **Objectif:** Trouver des mutations de résistances du VIH
- **Méthode:** Entraînement de classifieurs interprétables *traité/non-traité*
- **Résultats:** Identification de 6 nouvelles mutations potentiellement accessoires

Blassel, Tostevin, et al. 2021; Blassel, Zhukova, et al. 2021

Projet de recherche - Phylogénie sans vraisemblance

Inférence phylogénétique:

- x : alignement de **séquences**, θ : **arbre**,
- $p(x|\theta, M)$: **modèle** d'évolution

Fréquentiste: $\theta^* = \underset{\theta}{\operatorname{argmax}} p(x|\theta, M)$?

Bayésien: $P(\theta|x, M)$?

Inférence conditionnée sur un arbre:

- **Processus générateur**, e.g. modèle épidémio. avec R_0
- $P(R_0|\theta)$, $P(R_0|\theta, x)$, ...?


Problème:

Repose sur des **calculs répétés** de la **vraisemblance**


1. Estimation d'arbres phylogénétiques sans vraisemblance
 - Estimation neurale de Postérieure
 - Approche par diffusion
2. Estimation de paramètres à partir d'arbres phylogénétiques
 - Approche par GNN
 - Inférence jointe arbre/paramètres

Projet - Inférence sans vraisemblance (Travaux Post-doc)

Training time





Inference time



- **Objectif:** Prédire une matrice de distance phylogénétique correspondant à un alignement
- **Méthode:** Entraîner un transformer axial dans l'espace des paires de séquences
- **Résultats:** État de l'art dans la prédiction de distances
- **Limites:** Écart de performance en prédiction topologique


Nesterenko, Blassel, et al. 2025

Projet - Estimation de Postérieure (Travaux Post-doc)




- À l'entraînement $\psi^* = \underset{\psi}{\operatorname{argmin}} - \sum_{i \in \text{train}} \log q_{\psi(x_i)}(\theta_i|x_i)$
- Pendant l'inférence on échantillonne $q_{\psi^*(x_E)}(\theta_E|x_E)$

Projet - Estimation de Postérieure (Travaux Post-doc)




$$q_{\psi(x)}(\theta|x) = ?$$

Projet - Estimation de Postérieure (Travaux Post-doc)




$$q_{\psi(x)}(\theta|x) = p(m^{(1)})$$

Projet - Estimation de Postérieure (Travaux Post-doc)




$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)})$$

Projet - Estimation de Postérieure (Travaux Post-doc)



$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)}) \times p(m^{(3)}|m^{(1,2)})$$

Projet - Estimation de Postérieure (Travaux Post-doc)



$$q_{\psi(x)}(\theta|x) = p(m^{(1)}) \times p(m^{(2)}|m^{(1)}) \times p(m^{(3)}|m^{(1,2)}) \times p(m^{(4)}|m^{(1,2,3)})$$

TODO schematic with different encoders

- unaligned sequences

frame

CQSB:

Expertise: ML (L. Jacob), Évolution (M. Weigt, A. Carbone)

Collaborations: L. Jacob & P. Barrat-Charlaix

Équipe Bioinfo au LISN:

Expertise: SBI (F. Pouyet, F. Jay), Arbres & Graphes (L. Planche)

Équipe Modelling of Pathogens à l'IBENS & IP:

Expertise: Évolution & Phylogénie (A. Zhukova, H. Morlon)

Collaborations: A. Zhukova

References

- Blassel, L. et al. (2021). **Drug Resistance Mutations in HIV: New Bioinformatics Approaches and Challenges.** In: *Current Opinion in Virology* 51, pp. 56–64.
- Blassel, L. et al. (2021). **Using Machine Learning and Big Data to Explore the Drug Resistance Landscape in HIV.** In: *PLOS Computational Biology* 17.8, e1008873.
- Blassel, L. et al. (2022). **Mapping-Friendly Sequence Reductions: Going beyond Homopolymer Compression.** In: *iScience*, p. 105305.
- Faure, R. et al. (2025). **Alice: Fast and Haplotype-Aware Assembly of High-Fidelity Reads Based on MSR Sketching.** Pre-published.
- Nesterenko, L. et al. (2025). **Phyloformer: Fast, Accurate, and Versatile Phylogenetic Reconstruction with Deep Neural Networks.** In: *Molecular Biology and Evolution* 42.4, msaf051.

Transparents additionels

Schema

Projet - Inférence de séquences d'arbres

frame

Projet - Inférence sur les arbres

frame

env